



GitHub Trending Top 10

每日热门开源项目深度解读

2026-06-08

今日榜单

1	mvanhorn/last30days-skill AI agent skill that researches any topic across Reddit, X, YouTube, HN, Polymark...	Python	4天
2	RyanCodrai/turbovec A vector index built on TurboQuant, written in Rust with Python bindings	Python	NEW
3	google/skills Agent Skills for Google products and technologies	Python	NEW
4	refactoringhq/tolaria Desktop app to manage markdown knowledge bases	TypeScript	NEW
5	Panniantong/Agent-Reach Give your AI agent eyes to see the entire internet. Read & search Twitter, Reddi...	Python	4天
6	danielmiessler/Personal_AI_Infrastructure Agentic AI Infrastructure for magnifying HUMAN capabilities.	TypeScript	2天
7	santifer/career-ops AI-powered job search system built on Claude Code. 14 skill modes, Go dashboard,...	JavaScript	NEW
8	phuryn/pm-skills PM Skills Marketplace: 100+ agentic skills, commands, and plugins — from discove...	Unknown	NEW
9	openai/plugins OpenAI Plugins	JavaScript	2天
10	Andyyyy64/whichllm Find the local LLM that actually runs and performs best on your hardware. Ranked...	Python	NEW

#1

Python

连续 4 天

last30days-skill

AI agent skill that researches any topic across Reddit, X, YouTube, HN, Polymarket, and the web - then synthesizes a grounded summary

Stars **33,313** Forks **2,745** Today **+3,558**

<https://github.com/mvanhorn/last30days-skill>

好的，以下是对开源项目 `mvanhorn/last30days-skill` 的深度解读。

项目简介：这个项目是一个AI智能体技能，旨在成为“由人类真实互动驱动”的搜索引擎。它打破了传统搜索引擎依赖编辑排名的模式，通过并行搜索Reddit、X、YouTube、Hacker News、Polymarket等多个社交和内容平台，抓取帖子的点赞、评论、播放量等真实互动数据，并由AI裁判进行综合打分，最终生成一份关于任何话题的“最近30天”深度摘要。

核心功能：

- 跨平台聚合搜索：**能同时搜索多个“围墙花园”式平台（如Reddit、X、YouTube），获取Google、ChatGPT等单一AI无法触及的信息。
- 基于真实互动的评分：**不是依靠算法或编辑，而是根据用户的点赞、评论、甚至Polymarket上真金白银的投注赔率来评估信息的权重和可信度。
- AI智能摘要：**搜索到海量并行信息后，由一个AI智能体充当“法官”，将来自不同平台的碎片化信息综合成一份简洁、有据可依的摘要。
- 零配置与快速启动：**Reddit、Hacker News等核心源开箱即用，并提供一个30秒的设置向导来解锁X、YouTube等需要API密钥的源。

适用场景：

- 深度研究个人：**在会议或面试前，快速了解一个人的最新动态（推文、播客、代码提交），超越其LinkedIn简介。
- 市场与竞品分析：**了解一个公司或产品在社交媒体和开发者社区中的真实口碑、用户痛点和最新讨论。
- 追踪热点与技术趋势：**在AI等快速变化的领域，获取Reddit和X上“内行”们的最新见解和第一手消息，比训练数据更新更快。
- 旅行与消费决策：**例如去迪士尼前，了解各游乐设施的近期运营状态和社区真实评价。

技术亮点：

- Agent驱动的“搜索即编排”：**项目核心不是写一个爬虫，而是设计了一个AI智能体，它能自主决定搜索哪些源、如何并行调用API、如何对异构数据（文本、视频转录、赔率）进行归一化评分。
- “数据源桥接”模式：**项目巧妙地解决了单一AI模型（如Claude、GPT）无法访问所有平台数据的痛点。它允许用户“自带钥匙”（API密钥和浏览器Session），让AI代理成为连接各个数据孤岛的桥梁。
- 实时性优先：**设计哲学是“搜索过去30天”，强调信息的时效性，通过抓取高互动内容来捕捉社区当下的关注焦点，而非沉淀的、被SEO优化的旧信息。

上手建议：如果你是终端用户，推荐在Claude Code中通过市场插件一键安装，体验最流畅。如果你使用其他工具（如Cursor），可以通过`npx skills add`命令安装。项目README中提供了详细的安装指南。对于想贡献的开发者，可以阅读`skills/last30days/SKILL.md`文件，这是最新的技能规范，了解如何为其添加新的数据源或改进AI裁判的评分逻辑。

#2

Python

NEW

turbovec

A vector index built on TurboQuant, written in Rust with Python bindings

Stars **8,117** Forks **762** Today **+1,730**

<https://github.com/RyanCodrai/turbovec>

好的，作为一名资深的开源技术分析师，我很乐意为你解读这个项目。

项目简介

turbovec 是一个基于 Rust 编写、并提供 Python 接口的高性能向量索引库。它利用 Google 最新的 TurboQuant 量化算法，将向量数据的存储和检索效率提升到了新的高度，核心卖点是：**用极低的内存占用实现比 FAISS 更快的搜索速度**。它解决了在资源受限或对延迟敏感的场景下，大规模向量检索的痛点。

核心功能

1. **极致的内存压缩**：通过 TurboQuant 算法，可将向量数据的内存占用压缩至原来的 1/8（例如，1000 万文档从 31GB 降至 4GB）。
2. **在线增量索引**：支持随时添加新向量，无需单独的“训练”阶段或参数调优，也无需因数据增长而重建索引。
3. **高性能 SIMD 搜索**：通过手写的 ARM NEON 和 x86 AVX-512BW 内核，实现了比 FAISS IndexPQFastScan 快 12-20% 的搜索性能。
4. **原生支持过滤搜索**：允许在搜索时传入 ID 允许列表，搜索内核会直接在 SIMD 计算层面进行过滤，避免“先搜后筛”的性能浪费。
5. **主流框架集成**：提供了与 LangChain、LlamaIndex、Haystack 等主流 RAG 框架的即插即用集成，替换成本极低。

适用场景

- **隐私敏感的 RAG 应用**：任何希望将数据保留在本地、构建完全“气隙”的检索增强生成（RAG）系统的开发者或企业。
- **内存受限的部署**：在边缘设备、低配服务器或云实例上运行大规模向量搜索，需要极致的内存效率。

- **高吞吐、低延迟的搜索服务：**需要比 FAISS 更快、且能处理实时数据流的向量搜索场景，如实时推荐、相似图片搜索等。

技术亮点

- **核心算法 TurboQuant：**这是一个“数据无关”的量化器，无需像传统方法那样在训练集上学习码本，理论上可以达到香农失真下限，在压缩率和精度之间取得了极佳的平衡。
- **Rust 核心 + Python 绑定：**核心用 Rust 编写，保证了极致的性能和内存安全；同时通过 Python 绑定，使得数据科学家和 AI 工程师可以轻松使用，兼具了速度与易用性。
- **内核级过滤：**实现了“过滤即计算”的架构，将过滤逻辑嵌入到 SIMD 向量化计算的核心循环中，避免了传统方案中“拉取全量数据再过滤”的昂贵开销，这是其性能超越同类方案的关键设计。

上手建议

- **快速体验：**对于 Python 用户，最直接的方式是执行 `pip install turbovec`，然后参考 README 中的示例代码，只需几行代码即可创建一个索引并执行搜索。
- **深入使用：**阅读 docs/api.md 文档，了解 IdMapIndex（支持稳定 ID 和删除）和过滤搜索的详细用法。对于生产环境，建议从框架集成（如 LangChain 或 LlamaIndex）入手，替换原有的内存向量存储。
- **贡献代码：**项目主要使用 Rust 开发，如果你擅长 Rust 或对 SIMD 优化（NEON/AVX-512）有研究，可以关注其 GitHub 仓库的 Issue 和 Pull Request，从性能优化或新增功能入手。

#3

Python

NEW

skills

Agent Skills for Google products and technologies

Stars **12,146** Forks **953** Today **+481**

<https://github.com/google/skills>

好的，这是对 google/skills 项目的分析解读。

项目简介： 这是一个由 Google 官方维护的开源仓库，旨在为 AI Agent（智能代理）提供一系列“技能”，使其能够与 Google 的产品和技术（如 Google Cloud、Gemini API）进行交互。它解决了 Agent 如何标准化、模块化地调用特定 API 或执行特定任务的问题，让开发者无需从头编写集成代码。

核心功能： 1. **即装即用的技能包：** 提供针对 Google Cloud 核心服务（如 BigQuery, Cloud Run, Kubernetes）和 Gemini API 的预置技能，Agent 可以通过简单的命令行安装。2. **Recipe 技能：** 提供了“新手引导”和“认证”等复合型技能，用于指导 Agent 完成更复杂的多步骤任务流程，例如“登录 Google Cloud”。3. **架构框架技能：** 包含了 Google Cloud 良好架构框架（如安全性、可靠性、成本优化）的评估技能，帮助 Agent 对云架构进行最佳实践检查。

适用场景： * **AI 开发者：** 正在构建能自动操作 Google Cloud 的 AI Agent 或 Copilot 的开发者，可以直接使用这些技能来赋予 Agent 云管理能力。 * **云运维团队：** 利用 Agent 来执行日常的云资源查询、状态监控或架构合规性检查，提升运维效率。 * **应用集成：** 在需要 Agent 与 Google 生态（如 Firebase、Gemini）进行数据交互或功能调用的任何应用场景中。

技术亮点： 1. **标准化技能格式：** 项目遵循 `agentskills.io` 定义的开放标准，这意味着这些技能不仅可用于 Google 的工具，理论上也能兼容其他支持该标准的 Agent 框架，具有很好的可移植性。 2. **“食谱”式设计：** 通过“Recipe”技能将多个基础 API 调用组合成一个有逻辑的“菜谱”，让 Agent 能像人一样按步骤完成复杂任务，而不仅是单一的函数调用。 3. **社区驱动与开放许可：** 采用 Apache 2.0 许可，鼓励社区贡献和定制，这有助于技能库随着 Google 产品更新和用户需求快速迭代。

上手建议： 1. **快速体验：** 在终端运行 `npx skills add google/skills`，然后按照提示选择安装你需要的技能，例如“BigQuery Basics”。 2. **阅读文档：** 安装后，技能文件是 Markdown 格式的，可以直接阅读 `skills/cloud/` 目录下的文件，了解每个技能的具体指令和参数。 3. **贡献与反馈：** 如

果发现技能描述不准确或需要新的技能，可以直接在 GitHub 仓库提 Issue 或 Pull Request。从阅读现有的“Recipe”技能代码开始，是学习如何编写新技能的好方法。

#4

TypeScript

NEW

tolaria

Desktop app to manage markdown knowledge bases

Stars **13,296** Forks **931** Today **+649**

<https://github.com/refactoringhq/tolaria>

好的，这是对开源项目 `refactoringhq/tolaria` 的深度解读。

项目简介： Tolaria 是一款专为管理 Markdown 知识库而设计的跨平台桌面应用。它的核心价值在于，它不创造新的数据格式或依赖云端服务器，而是直接操作你本地的 Markdown 文件和 Git 仓库，确保你对自己的知识资产拥有完全的控制权。

核心功能： 1. **纯本地文件系统：** 所有笔记都是标准的 .md 文件，可以直接在任何文本编辑器中打开和编辑，无需导出。 2. **Git 原生集成：** 每个知识库 (vault) 都是一个 Git 仓库，自动提供完整的版本历史，并支持连接任何 Git 远程服务进行备份或协作。 3. **AI 友好：** 项目内置了对 Claude Code、Codex CLI 等 AI 工具的支持路径，让 AI 能直接理解并操作你的知识库文件。 4. **类型化导航：** 通过为笔记添加“类型”标签来辅助检索，但并非强制性的数据模式，更像是一种灵活的导航“镜头”。 5. **键盘优先设计：** 针对重度用户优化，支持通过命令面板和快捷键进行高效操作，减少对鼠标的依赖。

适用场景： - **个人知识管理：** 适合希望建立“第二大脑”的个人用户，用于整理笔记、日记、想法和项目资料。 - **团队文档协作：** 团队可以将公司文档以纯文件形式管理，方便作为 AI 的上下文，同时保证数据不锁定在特定软件中。 - **AI Agent 记忆库：** 可以作为 AI 助手的长期记忆和操作指南的存储库，由 AI 直接读写，实现更智能的自动化。

技术亮点： - **技术栈：** 采用 Tauri + React + TypeScript 构建，这使得应用体积小、性能高，且拥有原生的桌面体验。 - **架构理念：** 完全遵循“文件优先”和“离线优先”原则，不依赖任何后端服务，从根本上解决了数据所有权和隐私问题。 - **设计哲学：** 通过“类型作为镜头”和“AI-first but not AI-only”等理念，在灵活性和结构化之间取得了巧妙的平衡，避免了传统笔记软件过于死板或过于松散的问题。

上手建议： - **使用：** 最简单的方式是通过 Homebrew (`brew install --cask tolaria`) 或从 GitHub Releases 页面下载安装包。首次启动时，可以克隆官方的入门知识库来快速了解所有功能。 - **贡献：** 项目需要 Node.js 20+、pnpm 8+ 和 Rust 环境。可以按照项目文档中的 GETTING-

STARTED.md 指南配置本地开发环境，并关注 site/ 目录下的用户文档和 AGENTS 文件来理解项目结构。

#5

Python

连续 4 天

Agent-Reach

Give your AI agent eyes to see the entire internet. Read & search Twitter, Reddit, YouTube, GitHub, Bilibili, XiaoHongShu — one CLI, zero API fees.

Stars **23,697** Forks **1,999** Today **+961**

<https://github.com/Panniantong/Agent-Reach>

好的，作为一名资深开源技术分析师，我来为你解读这个项目。

项目简介： Agent-Reach 是一个为 AI Agent（如 Claude Code、OpenClaw）提供“互联网眼睛”的开源工具。它解决了 AI Agent 无法直接访问和解析众多网络平台（如推特、小红书、B站）内容的核心痛点，让 Agent 能像人一样去搜索、阅读和交互，而无需开发者去折腾每个平台的付费API或繁琐配置。

核心功能： 1. **一键集成：** 用户只需复制一句安装指令给AI Agent，工具便会自动完成所有依赖、配置和技能注册，实现“零门槛”接入。 2. **跨平台内容获取：** 支持Twitter、Reddit、YouTube、GitHub、Bilibili、小红书、抖音等20+主流平台，能读取网页、提取视频字幕、搜索帖子等。 3. **零API费用：** 所有功能均通过开源工具或免费接口实现（如Jina Reader、yt-dlp），无需为任何平台的官方API付费。 4. **Cookie本地化管理：** 对于需要登录的平台（如小红书），它通过用户本地导出的Cookie进行认证，确保隐私安全，代码完全开源可审查。

适用场景： - **AI Agent开发者：** 希望让自己的Agent具备联网搜索、社交媒体舆情分析、视频内容总结等能力，但不想花费时间对接各个平台的API。 - **高级用户/研究人员：** 使用Claude Code、Cursor等工具进行自动化工作流，需要Agent在互联网上自主查找、整理和对比信息。 - **内容创作者/运营：** 需要Agent定时监控多个平台的热点、竞品动态或用户反馈，并生成报告。

技术亮点： - **“工具链整合”而非“造轮子”：** 项目巧妙地将yt-dlp、twitter-cli、Jina Reader等成熟的开源命令行工具整合到一个统一的CLI框架下，通过SKILL.md让AI Agent学会调用这些工具，技术思路非常务实。 - **“一句话安装”的极简体验：** 通过一个精心设计的安装脚本，自动完成环境检测、依赖安装、工具配置和Agent技能注册，大大降低了使用门槛，这是项目爆火的关键。 - **“自动诊断”与“持续更新”：** 内置agent-reach doctor命令让用户能快速排查问题；同时承诺追踪各平台的反爬机制变化并更新底层工具，解决了开源项目常见的“用着用着就失效”的痛点。

上手建议：

- **使用者：**最直接的方式就是复制README中那句安装指令给你的AI Agent（如Claude Code），它会引导你完成所有步骤。安装后，尝试告诉它“帮我看看这个YouTube视频讲了什么”或“搜一下小红书上这个产品的口碑”，体验其威力。
- **贡献者：**项目目前主要依赖整合现有工具，贡献者可以关注其支持的平台列表，为尚未支持或需要配置的平台（如抖音、LinkedIn）贡献新的适配器或改进现有工具的集成方式。

#6

TypeScript

连续 2 天

Personal_AI_Infrastructure

Agentic AI Infrastructure for magnifying HUMAN capabilities.

Stars **15,250** Forks **2,148** Today **+337**

https://github.com/danielmiessler/Personal_AI_Infrastructure

好的，这是对 danielmiessler/Personal_AI_Infrastructure 项目的分析解读。

项目简介：这是一个名为 **PAI** 的“生活操作系统”开源项目。它的核心目标不是构建一个通用的AI助手，而是为每个人打造一个能放大自身能力的、高度个性化的AI基础设施。它解决的核心问题是：如何让AI真正理解你、服务你，而不是让你去适应AI。

核心功能：

- Pulse守护进程：**一个统一的生命仪表盘，运行在localhost:31337，用于集中管理和查看你的AI系统状态。
- DA（数字助理）身份层：**为你的AI助手创建一个独立的、可配置的身份，使其行为更符合你的个人风格和需求。
- Algorithm v6.3.0：**一套核心算法，指导AI从“当前状态”到“理想状态”的思考与行动，包含分类器驱动的模式选择。
- ISA原语：**一种通用的“理想状态”描述语言，让你能清晰地告诉AI你想要达成的目标。

适用场景：适合那些希望深度定制和掌控自己AI体验的开发者、技术爱好者和效率狂人。典型场景包括：将个人知识库与AI深度整合、自动化日常复杂 workflows、构建一个能够代表你进行思考和决策的**个人AI代理**。

技术亮点：

- 架构理念：**强调“结构性隐私”，通过“包含区域（containment zones）”来隔离不同场景下的数据，在功能与隐私间取得平衡。
- 资源丰富：**项目包含了**45个技能**、**171个工作流**和**37个钩子**，构成了一套即插即用的AI能力库，降低了二次开发成本。
- 技术栈现代化：**基于TypeScript和Bun构建，与Claude深度集成，体现了当前AI应用开发的前沿实践。

上手建议：该项目提供了一键安装脚本（`curl -sSL https://ourpai.ai/install.sh | bash`），非常方便。如果你是v4.x用户，需要先阅读**迁移指南**。对于想贡献的开发者，可以从阅读Releases/v5.0.0/目录下的**算法文档**和**Pulse模块**开始，了解其核心设计哲学。

#7

JavaScript

NEW

career-ops

AI-powered job search system built on Claude Code. 14 skill modes, Go dashboard, PDF generation, batch processing.

Stars **50,077** Forks **10,299** Today **+665**

<https://github.com/santifer/career-ops>

好的，这是对 career-ops 项目的深度解读。

项目简介： 这是一个将AI编程助手（如Claude Code）改造为自动化求职系统的开源工具。它解决了求职者手动筛选海量职位、为每家公司定制简历的痛点，将整个求职流程变成一个可量化、可批处理的工程化流水线。

核心功能： 1. **智能评分与筛选：** 基于10个加权维度（如薪资、文化、技能匹配度）对职位进行A-F等级评分，自动过滤掉低分职位，避免无效申请。 2. **自动化简历定制：** 能根据每个职位的描述，自动生成针对ATS（招聘系统）优化的个性化PDF简历，实现“千人千面”。 3. **多平台批量处理：** 自动扫描Greenhouse、Ashby、Lever等主流招聘平台及公司官网，并能并行处理10个以上的职位评估。 4. **数据追踪仪表盘：** 提供一个Go语言编写的仪表盘，将所有申请状态、评分和历史记录集中管理，形成求职数据的中枢。

适用场景： 适合正在积极寻找工作、希望提升效率和申请质量的软件工程师、产品经理等技术从业者。特别是那些每天需要面对数十甚至上百个职位，希望用最少时间找到最匹配机会的求职者。

技术亮点： 1. **“Agentic”设计：** 项目并非简单的API调用，而是让AI（Claude Code）像“代理”一样自主行动——使用Playwright浏览网页、深度推理简历与职位的匹配度（而非关键词匹配），并动态调整策略。 2. **多Agent并行架构：** 通过“子代理”并行评估多个职位，大幅提升处理速度，体现了工程化的高效思维。 3. **全栈技术融合：** 巧妙地将AI（Claude/Gemini等）、前端（JavaScript/Go仪表盘）、自动化（Playwright）和文档生成（PDF）整合为一个完整的求职工具链。

上手建议： 首先，你需要准备好一个支持MCP协议的AI CLI工具（如Claude Code）和API密钥。然后，从项目的README开始，按照“快速开始”指南配置你的个人信息和偏好。建议先让系统评估少量职位，熟悉其评分逻辑和输出，再逐步扩大到批量处理。贡献者可以从改进职位解析器或增加新的招聘平台支持入手。

#8

Unknown

NEW

pm-skills

PM Skills Marketplace: 100+ agentic skills, commands, and plugins — from discovery to strategy, execution, launch, and growth.

Stars **12,419** Forks **1,484** Today **+112**

<https://github.com/phuryn/pm-skills>

好的，这是对 phuryn/pm-skills 项目的深度解读。

项目简介： 这是一个将产品管理（PM）的最佳实践系统化、工具化的开源项目。它解决的核心问题是，如何让AI助手（如Claude）从“生成通用文本”升级为“执行专业的PM workflow”，帮助产品经理做出更明智的决策，而不仅仅是生成更快的文档。

核心功能： 1. **技能库：** 内置了超过100个经过验证的PM框架（如机会解决树、假设映射），AI能根据对话上下文自动调用。 2. **命令系统：** 提供 /discover、/write-prd 等“一键式”命令，可自动串联多个技能，完成从发现到发布的端到端流程。 3. **插件化安装：** 将技能和命令按PM领域（如策略、执行、增长）打包成9个插件，用户可按需安装，集成到Claude Code等AI开发环境中。

适用场景： - **产品经理：** 在日常工作中快速启动结构化分析，如撰写PRD、规划产品发布、进行市场研究。 - **AI编程用户：** 在使用Claude Code或Codex CLI进行开发时，同步获得产品决策支持，确保技术实现与产品目标对齐。 - **团队协作：** 统一团队内部的产品工作方法论，降低沟通成本，让AI成为团队的标准作业流程执行者。

技术亮点： 1. **“技能即代码”：** 将非结构化的PM方法论编码为AI能理解、执行的模块化“技能”，实现了领域知识与AI能力的深度耦合。 2. **工作流编排：** 并非简单提供单个技能，而是通过/command实现了技能的链式调用，模拟了真实的产品工作流，这是其智能化的关键。 3. **跨平台兼容：** 设计上兼容Claude Code、Cocowork以及Codex CLI，并提供了标准化的安装指令，降低了用户的接入门槛。

上手建议： 如果你是产品经理，推荐从最易用的 **Claude Cowork** 开始，在其设置中添加该市场，即可获得所有插件。如果你是开发者，可以按照README中的指引，通过 `claude plugin marketplace add phuryn/pm-skills` 命令在CLI环境中安装。想要贡献的话，可以查看CONTRIBUTING.md文件，提交新的PM技能或改进现有工作流。

#9

JavaScript

连续 2 天

plugins

OpenAI Plugins

Stars **2,209** Forks **278** Today **+296**<https://github.com/openai/plugins>

好的，作为一名资深开源技术分析师，我很乐意为您解读这个项目。

项目简介： 这是一个由 OpenAI 官方维护的“插件”示例仓库，旨在展示如何为 OpenAI 的 Codex 模型（可以理解为一种高级代码生成AI）构建扩展功能。它解决了 AI 模型能力边界的问题，让 AI 不仅能写代码，还能直接与 Figma、Notion 等外部工具和平台交互，执行更复杂的任务。

核心功能： 1. **标准化的插件清单：** 每个插件通过 `plugin.json` 文件定义其身份、能力和入口，为 AI 模型提供了清晰的调用接口。 2. **丰富的官方示例：** 仓库提供了 Figma、Notion、iOS/Web 应用构建等多个真实场景的插件模板，是开发者学习和复用的最佳起点。 3. **技能与模型上下文协议（MCP）支持：** 插件可以包含 `skills/`（技能定义）和 `.mcp.json`（模型上下文协议配置），让 AI 理解其能做什么以及如何调用外部服务。 4. **多类型资源整合：** 支持 `agents/`、`commands/`、`hooks.json` 等文件，允许插件定义更复杂的自动化流程和交互逻辑，而不仅仅是简单的工具调用。

适用场景： 这个项目主要面向 AI 应用开发者、SaaS 平台集成工程师以及对 AI 能力有深度定制需求的开发者。例如，一个产品经理可以用它来快速创建一个“Figma 插件”，让 AI 根据设计稿自动生成代码；或者开发者用它构建一个“Notion 插件”，让 AI 自动整理会议纪要和任务清单。

技术亮点： 技术上的亮点在于其设计哲学——将**声明式配置**与**可执行逻辑**分离。通过 `plugin.json`、`skills/` 等元数据文件，AI 模型可以自省地了解插件的能力，无需硬编码。同时，引入 MCP 标准，使得插件与外部服务（如数据库、API）的交互变得标准化和可复用，这是构建复杂 AI Agent 的关键。

上手建议： 建议从目录结构入手，先阅读 `plugins/` 下的任意一个简单示例（如 `plugins/google-slides`），理解 `plugin.json` 和 `skills/` 的基本配置。然后，重点研究 `plugins/figma` 或 `plugins/notion` 等复杂示例，了解如何定义多步骤的技能（Skills）和调用外部 API。最后，基于自己的需求，在 `plugins/` 下新建文件夹，复制并修改一个最接近的示例即可开始贡献。

#10

Python

NEW

whichllm

Find the local LLM that actually runs and performs best on your hardware. Ranked by real, recency-aware benchmarks, not parameter count. One command, run it instantly.

Stars **3,219** Forks **192** Today **+103**

<https://github.com/Andyyyy64/whichllm>

好的，这是对 whichllm 项目的深度解读。

项目简介： whichllm 是一个命令行工具，旨在解决一个实际痛点：用户拥有本地硬件（如显卡），但面对海量的大语言模型（LLM），不知道哪一款能在自己的设备上流畅运行且效果最佳。它不再是简单地看模型参数量，而是通过实时跑分和硬件适配度，帮你一键找到最优解。

核心功能： 1. **一键推荐：** 运行 whichllm 即可自动检测你的GPU/CPU/内存，并推荐最适合你硬件的模型列表，按综合得分排序。 2. **硬件模拟：** 使用 --gpu 参数，可以在不更换硬件的情况下，模拟特定显卡（如RTX 4090）的推荐结果，方便购买前做决策。 3. **模型规划：** 使用 whichllm plan，可以反向查询运行特定模型（如“llama 3 70b”）所需的最低显卡配置。 4. **一键运行与代码生成：** whichllm run 可直接下载并启动模型聊天；whichllm snippet 能为指定模型生成可直接运行的Python代码片段。

适用场景： - **AI 爱好者与开发者：** 想在自己的PC或Mac上本地运行LLM，但面对HuggingFace上成千上万的模型感到困惑，希望快速找到“最优解”。 - **硬件选购者：** 在购买新显卡（如RTX 5090、4090）前，想模拟评估不同硬件能带动哪些模型、性能如何。 - **自动化脚本与工作流：** 需要将模型选择集成到CI/CD或自动化脚本中，whichllm 的 --json 输出格式可以方便地被其他程序解析。

技术亮点： - **智能评分机制：** 不只看模型能不能装下（VRAM），而是综合**真实跑分**（集成LiveBench、Arena ELO等多个榜单）、**时效性**（更新模型权重，避免过时模型排名虚高）和**推理速度**（考虑量化、MoE架构等因素）进行排名。 - **硬件感知的精确估算：** 不仅估算权重占用的显存，还精确计算了KV Cache、激活内存和系统开销，并根据不同硬件（NVIDIA/AMD/Apple Silicon）和内存类型（统一内存/PCIe）建模，预测更准确。 - **数据可信度分级：** 给每个得分打上“直接”、“变体”、“插值”等标签，并拒绝虚假的上传者声明，确保推荐结果可靠。

上手建议： 对于使用者，最简单的方式是执行 `uvx whichllm@latest` 命令，无需任何安装即可体验。日常使用建议通过 `pip install whichllm` 或 `brew install whichllm` 安装。对于想贡献代码的开发者，可以关注其GitHub仓库，该项目使用Python 3.11+，结构清晰，可从测试和文档贡献入手。

数据来源: github.com/trending

报告日期: 2026-06-08

由 DeepSeek AI 提供智能分析 | 自动生成