



GitHub Trending Top 10

每日热门开源项目深度解读

2026-08-03

今日榜单

- 1 lyogavin/airllm** Jupyter Notebook
AirLLM 70B inference with single 4GB GPU 2天
- 2 zhaoxuya520/reverse-skill** PowerShell
Reverse Engineering / Authorized Penetration Testing / Security Research Skill R... 4天
- 3 firecrawl/pdf-inspector** Rust
Fast Rust library for PDF inspection, classification, and text extraction. Intel... NEW
- 4 esengine/DeepSeek-Reasonix** Go
DeepSeek-native AI coding agent for your terminal. Engineered around prefix-cach... NEW
- 5 TencentCloud/TencentDB-Agent-Memory** TypeScript
TencentDB Agent Memory is a team-level memory hub for AI Agents — turning conver... 2天
- 6 microsoft/AI-For-Beginners** Jupyter Notebook
12 Weeks, 24 Lessons, AI for All! 5天
- 7 microsoft/generative-ai-for-beginners** Jupyter Notebook
21 Lessons, Get Started Building with Generative AI 2天
- 8 donnemartin/system-design-primer** Python
Learn how to design large-scale systems. Prep for the system design interview. I... NEW
- 9 antirez/ds4** C
DeepSeek 4 Flash and PRO local inference engine for Metal, CUDA and ROCm NEW
- 10 shiyu-coder/Kronos** Python
Kronos: A Foundation Model for the Language of Financial Markets NEW

#1

Jupyter Notebook

连续 2 天

airllm

AirLLM 70B inference with single 4GB GPU

Stars **26,303** Forks **2,926** Today **+1,081**<https://github.com/lyogavin/airllm>

项目简介：AirLLM 是一个极具影响力的开源推理优化项目，它通过创新的内存管理技术，让显存仅 4GB 的普通 GPU 也能运行 70B 参数的大语言模型。该项目解决了大模型推理对硬件要求过高、普通用户难以触及的核心痛点，目前已在 GitHub 上获得超过 2.6 万星标，并持续快速升温。

核心功能：其一，单卡运行超大模型，无需量化、蒸馏或剪枝，即可在 4GB 显存上运行 70B 模型，甚至可以在 8GB 显存上跑 405B 模型。其二，支持广泛的最新模型架构，包括 Llama 3.x/4、DeepSeek-V3 (671B)、Qwen3 以及 2.8T 参数的 Kimi K3 等。其三，提供统一的 AutoModel 接口，自动识别模型类型，并支持 FP8 精度、CPU 推理和 8bit/4bit 量化选项。

适用场景：主要面向资源受限的研究者、独立开发者和 AI 爱好者，他们希望在个人消费级显卡或 Mac 上体验和部署前沿大模型。也适用于需要快速原型验证、教学演示，以及预算有限但需要本地化部署大模型的中小团队。

技术亮点：其核心创新在于"层流式"推理机制——按需逐层加载模型权重，而非一次性载入全部参数，从而将显存需求降低一个数量级。对于 MoE（混合专家）模型，它进一步实现了"专家级"流式加载，只加载当前 token 路由到的专家，这使得 2.8T 的 Kimi K3 也能在不到 4GB 显存中运行。此外，项目还引入了预取机制来重叠模型加载与计算，提升约 10% 的运行速度。

上手建议：使用非常简单，只需通过 `pip install airllm` 安装，然后调用 AutoModel 接口加载模型即可。建议从官方提供的 Colab 示例笔记本（如 Llama3.1 405B 示例）开始体验。若想贡献代码，可从 GitHub Issues 中寻找待办任务，或针对新模型支持、推理速度优化和内存管理等方面提交改进。

#2

PowerShell

连续 4 天

reverse-skill

Reverse Engineering / Authorized Penetration Testing / Security Research Skill Router
Pack AI-powered routing + On-demand toolchain bootstrapping + Self-evolving
knowledge base Supports Claude Code, Kiro, Cursor, Cline, and other AI coding
clients 逆向/渗透/安全技能路由包 - AI 自动路由 + 按需自举工具链 + 自动进化经验库 | 支持
Claude Code / Kiro / Cursor / Cline 等代码 AI 客户端

Stars **14,946** Forks **2,203** Today **+2,442**

<https://github.com/zhaoxuya520/reverse-skill>

项目简介：

reverse-skill 是一个面向 AI 编程助手的“安全技能路由包”，当 AI 遇到 APK、二进制文件、前端 JS 加密或渗透测试任务时，它会自动匹配对应的逆向/安全方法论，并引导 AI 按规范流程执行，而不是瞎猜命令。简单说，它把零散的安全工具和经验，打包成了 AI 能直接调用的“技能导航系统”。

核心功能：

1. **智能路由**：根据任务类型（APK/ELF/JS/PCAP/CTF）自动分发到对应技能路径（MASTER-ROUTING.md）。
2. **工具链自举**：自动检测本机已安装的工具（jadx、Frida、IDA 等）并生成索引，缺啥补啥。
3. **经验自进化**：通过 timeline + Evidence→Finding→Path 结构沉淀每次分析过程，形成可复用的知识库。
4. **多客户端兼容**：支持 Claude Code、Cursor、Cline、Codex CLI 等主流 AI 编程工具。

适用场景：

主要面向安全研究人员、逆向工程师和渗透测试人员，尤其是那些用 AI 辅助做 APK 逆向、CTF 解题、前端加密分析或授权渗透测试的人。也适合想规范自己安全分析流程、避免重复踩坑的团队。

技术亮点：

项目用 PowerShell 和 Bash 写了跨平台的工具检测脚本，把“AI 决策”和“本地工具执行”解耦——AI 只负责按路由规则选路，具体命令由脚本按契约执行。这种“规则驱动 + 脚本自举”的设计，让 AI 的行为变得可预测、可审计，比让 AI 自由发挥要稳得多。

上手建议：

先 git clone 项目，然后按平台跑一下 refresh-tool-index 脚本生成工具索引。接着给 AI 客户

端（如 Claude Code）指定项目根目录，让它读 `README_AI.md` 和 `MASTER-ROUTING.md` 即可开始使用。想贡献的话，可以从补充新的场景路由或优化工具检测脚本入手。

#3

Rust

NEW

pdf-inspector

Fast Rust library for PDF inspection, classification, and text extraction. Intelligently detects scanned vs text-based PDFs to enable smart routing decisions.

Stars **6,799** Forks **478** Today **+1,769**

<https://github.com/firecrawl/pdf-inspector>

项目简介：pdf-inspector 是 Firecrawl 开源的一个高性能 Rust PDF 解析库，能在毫秒级完成 PDF 的类型分类和文本提取。它主要解决一个实际痛点：大约 54% 的 PDF 是纯文本格式，无需昂贵的 OCR 服务，该项目能智能识别并跳过这些不必要的计算开销。

核心功能：智能分类可在 10-50ms 内判断 PDF 是文本型、扫描型还是混合型，并给出置信度分数；位置感知的文本提取支持多栏阅读顺序和 RTL 文本；高质量 Markdown 转换涵盖标题、列表、代码块、表格等结构化元素；独特的双模式表格检测（基于矩形绘制操作和文本对齐启发式）；此外还提供 Python、Node.js 和浏览器 WebAssembly 绑定。

适用场景：主要面向需要处理大量 PDF 的开发者，特别是报告、论文、财务报表、发票和法律文档的解析场景。适合 RAG 管道、文档管理系统、数据分析工具等需要将 PDF 转换为结构化文本的应用，也适合需要本地快速处理、避免 OCR 延迟和基础设施成本的服务端应用。

技术亮点：纯 Rust 实现，无机器学习模型依赖，仅依赖 lopdf 单个库进行 PDF 解析，保证了极快的速度（200 个文档仅需 0.47 秒）。在基准测试中，其整体得分、阅读顺序和表格识别均优于 liteparse、PyMuPDF4LLM 等竞品。特别值得关注的是其单次文档加载机制——检测和提取共享同一份解析结果，避免了冗余 I/O，且支持 CID 字体解码和编码问题自动检测。

上手建议：如果你是使用者，可直接通过 pip、npm 或 Cargo 安装对应语言的绑定，Python 用户只需 `pip install pdf-inspector` 即可开始。若想贡献代码，可从 GitHub 仓库的 issues 入手，特别是测试和基准测试相关的部分，项目提供了可复现的基准测试框架，方便验证改动效果。建议先阅读 docs/ 目录下的 API 文档和基准测试说明，了解项目的设计理念。

#4

Go

NEW

DeepSeek-Reasonix

DeepSeek-native AI coding agent for your terminal. Engineered around prefix-cache stability — leave it running.

Stars **29,603** Forks **1,905** Today **+877**

<https://github.com/esengine/DeepSeek-Reasonix>

项目简介：DeepSeek-Reasonix 是一个专为 DeepSeek 模型打造的终端 AI 编程助手，核心卖点是“为前缀缓存而生”——通过保持上下文稳定来降低长会话中的 token 成本。它本质上是一个配置和插件驱动的框架，以单个 Go 静态二进制文件分发，可以常驻终端持续工作。

核心功能：① 全配置驱动，模型、工具、插件均在 `reasonix.toml` 中声明，无硬编码；② 多模型组合，可同时运行执行器+规划器两个模型，各自保持独立的缓存稳定会话；③ 插件生态，外部工具通过 stdio JSON-RPC（兼容 MCP）作为子进程运行，内置工具编译期自注册；④ 缓存感知的上下文维护，启动时注入稳定环境摘要，自动裁剪过期工具输出再压缩。

适用场景：适合深度使用 DeepSeek 模型进行日常编码的开发者，尤其是长时间、多轮次的交互式编程会话——比如持续重构、跨文件调试、需要模型长期“记住”项目上下文的任务。也适合希望将 DeepSeek 接入自定义工作流（通过插件）或需要低成本运行 AI 助手的团队。

技术亮点：前缀缓存优化是核心创新——通过保持系统提示和早期上下文不变，让 DeepSeek 的 KV cache 命中率最大化，显著降低 API 费用。实现上采用纯 Go 单二进制（CGO_ENABLED=0），交叉编译六个平台只需一条命令，依赖仅一个 TOML 解析器，工程极简。同时支持 npm/Homebrew 安装，并提供桌面应用和 VS Code 扩展三种形态。

上手建议：想体验的话，最简单的方式是 `npm i -g reasonix` 或 `brew install esengine/reasonix/reasonix`，然后按 README 配置 `reasonix.toml` 填入 DeepSeek API key。想贡献代码，可以从阅读 `docs/SPEC.md` 和 `docs/ACP.md` 开始了解架构，项目有活跃的 Discord 社区（中英双语）可以获取帮助和讨论 feature 想法。

#5

TypeScript

连续 2 天

TencentDB-Agent-Memory

TencentDB Agent Memory is a team-level memory hub for AI Agents — turning conversations, docs, and code into four reusable memory assets (Chat Memory, Skill, LLM-Wiki, Code-Graph) that are governed, shared, and equipped across agents and frameworks.

Stars **11,683** Forks **1,110** Today **+1,091**

<https://github.com/TencentCloud/TencentDB-Agent-Memory>

项目简介：TencentDB Agent Memory 是腾讯云推出的团队级 AI 智能体记忆中枢，旨在解决智能体重复劳动的问题——项目上下文、文档知识和已有经验无需在每次新会话中重新灌输。它将对话、文档和代码转化为可复用的记忆资产，让经验在智能体团队中积累、流通和传承。

核心功能：一是自动资产提取，从对话中提炼聊天记忆和技能，将文档与代码转化为 Wiki 和代码图谱；二是框架无关的资产共享，记忆资产可在不同智能体框架间流转，支持多智能体协同维护；三是冷启动友好，可直接导入已有文档、代码库和会话记录，让新团队从既有经验起步而非从零学习；四是分层记忆蒸馏，从原始对话逐层提炼出原子记忆、场景记忆和人物画像。

适用场景：面向深度使用 AI 编码助手（如 Claude Code、CodeBuddy）的开发团队，尤其是在大型项目中需要持续维护上下文一致性的场景。也适用于一人公司或小团队搭建"智能体团队"，让多个智能体共享团队记忆、避免重复解释项目背景和业务规则。

技术亮点：采用三层架构设计（memory-core 存储引擎 + memory-hub 管理中枢 + proxy 代理层），通过标准协议解耦记忆资产与智能体框架，实现跨框架移植。安装部署极简，一条命令启动全部服务，并提供了从旧版本到新版本的数据迁移工具，体现了工程化成熟度。

上手建议：从安装入手——克隆仓库后复制 `.env.example` 配置两组 LLM 参数，运行 `./start-all.sh` 即可启动全部服务，面板地址为 `localhost:8125`。建议先导入一个真实项目的代码和文档，体验自动生成的 CodeGraph 和 Wiki，再让智能体在项目任务中自然沉淀 Chat Memory，感受团队记忆的累积效应。

#6

Jupyter Notebook

连续 5 天

AI-For-Beginners

12 Weeks, 24 Lessons, AI for All!

Stars **60,315** Forks **11,808** Today **+1,902**<https://github.com/microsoft/AI-For-Beginners>

项目简介：这是微软推出的免费AI入门课程，用12周24节课的体系化内容，帮助零基础学习者系统掌握人工智能核心知识。它解决了AI学习资源碎片化、门槛高的问题，提供了一条清晰的学习路径。

核心功能：课程覆盖神经网络、计算机视觉、自然语言处理等AI核心领域，每个章节配有实战代码（基于TensorFlow和PyTorch）、测验和实验项目。项目还提供超过50种语言的自动翻译版本，并支持通过Binder在线运行代码，无需本地配置环境。

适用场景：适合想转行AI的产品经理、软件工程师、学生，以及需要给团队做AI科普的技术管理者。无论是自学还是作为企业内部培训教材，都能通过“理论+代码+测验”的组合快速建立知识框架。

技术亮点：项目采用Jupyter Notebook作为主要载体，将讲解、代码和运行结果无缝融合，降低了学习曲线。其多语言翻译通过GitHub Action自动同步更新，保证了内容的时效性，这种“课程即代码”的维护方式在开源教育项目中颇具创新性。

上手建议：直接按课程顺序从第1周开始学习，建议配合官方提供的Sketchnote视觉笔记快速预览每课要点。想贡献的话，可以从翻译校对或提交新测验题入手，项目对PR非常友好，且维护活跃。

#7

Jupyter Notebook

连续 2 天

generative-ai-for-beginners

21 Lessons, Get Started Building with Generative AI

Stars **115,251** Forks **61,387** Today **+776**

<https://github.com/microsoft/generative-ai-for-beginners>

项目简介：这是微软官方出品的生成式 AI 入门教程，用 21 节循序渐进的课程，帮助零基础开发者快速掌握构建生成式 AI 应用所需的核心知识。项目解决了初学者面对 AI 技术时“不知从何下手、资料碎片化”的痛点，提供了一条系统化的学习路径。

核心功能：一是完整的 21 课课程体系，覆盖从 Prompt 工程到 RAG 模式等核心主题；二是每个课程都配备可运行的 Jupyter Notebook 代码示例，边学边练；三是提供 50+ 种语言的自动翻译版本，极大降低了非英语开发者的学习门槛；四是配套 Azure AI 云服务集成指南，让学习者能直接上手真实场景。

适用场景：适合对生成式 AI 感兴趣的软件开发者、数据科学家、产品经理以及技术决策者。无论是想快速了解 LLM 应用开发基础，还是希望将 AI 能力集成到现有产品中，都能从中获得从理论到实战的完整指引。

技术亮点：项目采用“理论 + 代码 + 作业”三位一体的教学设计，每个课程都包含明确的学习目标和动手实验。翻译支持通过 GitHub Action 自动维护，确保多语言内容始终与英文原版同步，这种社区驱动的本地化模式在开源教育项目中颇具创新性。

上手建议：建议按顺序学习前 5 课打好基础，再根据兴趣选择后续专题。如果只想快速浏览，可以直接看每课的 README 摘要和代码示例。想贡献的话，可以从修复文档错别字、补充翻译或提交新的课程案例开始，项目对 PR 非常友好。

#8

Python

NEW

system-design-primer

Learn how to design large-scale systems. Prep for the system design interview.
Includes Anki flashcards.

Stars **360,284** Forks **57,511** Today **+138**

<https://github.com/donnemartin/system-design-primer>

项目简介：

这是一个系统设计学习资源库，旨在帮助开发者掌握大规模系统架构设计，同时为技术面试中的系统设计环节做准备。项目以开源协作方式持续更新，汇集了分散在网络上的大量设计原则和实战案例。

核心功能：

1. 提供系统设计核心概念的系统化摘要，涵盖可扩展性、可用性、一致性等关键主题。
2. 包含常见系统设计面试题及详细参考解答（含图表、代码和讨论）。
3. 内置Anki间隔重复记忆卡，帮助用户高效巩固知识点。
4. 提供面向对象设计面试题及解答，覆盖更广的面试需求。
5. 支持多语言翻译，降低非英语开发者的学习门槛。

适用场景：

主要面向准备技术面试的软件工程师，尤其是目标为大型科技公司（如Google、Amazon）的求职者。同时适用于希望系统提升架构设计能力的在职开发者，以及计算机专业学生作为课程补充材料。

技术亮点：

项目以“一切皆有取舍”（trade-off）为核心教学理念，强调对比不同方案的利弊。内容组织上采用分层索引结构，从基础概念到复杂案例层层递进，并配有大量可视化图表。此外，Anki卡片的间隔重复算法设计，使复习效率远高于传统笔记方式。

上手建议：

新手建议从“系统设计主题：从这里开始”章节入手，先观看可扩展性视频讲座，再按索引顺序逐步深入。面试备考者可优先练习“常见面试题及解答”部分，并配合Anki卡片做日常复习。贡献者可从修复文档错误、翻译或补充新主题开始，提交前务必阅读贡献指南。

#9

C

NEW

ds4

DeepSeek 4 Flash and PRO local inference engine for Metal, CUDA and ROCm

Stars **20,218** Forks **1,789** Today **+385**

<https://github.com/antirez/ds4>

项目简介：

DwarfStar (ds4) 是一个专注为 DeepSeek V4 Flash 和 PRO 模型打造的本地推理引擎，用 C 语言编写，目标是在个人高端硬件（如 128GB 内存的 MacBook 或 512GB 工作站）上高效运行大模型。它不是通用的 GGUF 运行器，而是为少数精选模型深度优化的“小而专”方案，解决了消费级硬件跑顶级开源模型的性能与内存瓶颈问题。

核心功能：

1. 多后端支持：原生适配 Metal（苹果）、CUDA（英伟达，含多 GPU 和 DGX Spark）和 ROCm（AMD Strix Halo）。
2. SSD 流式加载：内存不足时可用 SSD 换速度，让 96GB 以下机器也能跑大模型。
3. 多机并行：支持 RDMA 张量并行（两台 Mac 合跑）和流水线并行（多系统聚合内存）。
4. 服务器模式（ds4-server）：微批处理解码与生成，可将老式 Ada Lovelace 显卡（vLLM 已弃用）改造成公司内部多用户 LLM 服务，实测 8×L40S 聚合生成 120 t/s、预填充 2000 t/s。
5. 工具链完整：附带 GGUF 生成、imatrix 采集、质量对比、速度基准和方向性操控（dir-steering）等配套工具。

适用场景：

- 个人开发者/研究者：在 MacBook Pro (96GB+)、DGX Spark 或 Framework Desktop 上本地跑 DeepSeek V4 或 GLM 5.2，用于编程辅助、长上下文分析。
- 企业/团队：用闲置的旧 CUDA 显卡集群搭建内部 LLM 服务，替代 vLLM 不支持的硬件。
- 极客玩家：通过多机并行把两台 Mac 或工作站“拼”成一台大内存推理机，挑战更大模型。

技术亮点：

- 深度定制而非通用：仅针对 DeepSeek V4 Flash/PRO 和 GLM 5.2 做优化，包括激进的路由专家量化（routed-expert quantization）和压缩 KV 缓存，换取远超通用框架的性能。
- 不链接 GGML 却深受其恩：代码独立实现，但借用了 llama.cpp 的量化格式、内核和 GGUF 生态，并保留 MIT 版权声明，体现了开源传承。

- 坦诚的 AI 辅助开发：明确声明由 GPT-5.5/5.6 和 Claude Fable 强力辅助编码，人类主导测试调试，这种透明度在开源界少见。
- 性能数据亮眼：多 GPU 微批处理下聚合生成 120 t/s，预填充 2000 t/s，展示了专用引擎的潜力。

上手建议：

- 使用者：先看 README 中的“正常使用”章节，确认你的硬件（Mac 96GB+、NVIDIA 卡或 Strix Halo）和内存，然后从 GitHub Releases 下载对应后端构建，或用 SSD 流式模式跑小量化模型试水。
- 贡献者：务必先读 CONTRIBUTING.md，了解正确性和速度回归测试流程，再提交 PR；想深入工具链可看 gguf-tools/README.md。
- 注意：项目处于 beta 阶段，变化很快，建议关注 release 前的 QA 矩阵（QA_BEFORE_RELEASES.md）了解稳定性。

#10

Python

NEW

Kronos

Kronos: A Foundation Model for the Language of Financial Markets

Stars **35,720** Forks **5,954** Today **+217**

<https://github.com/shiyu-coder/Kronos>

项目简介：Kronos 是首个专为金融市场 K 线（蜡烛图）数据设计的开源基础模型，由 shiyu-coder 团队开发，已入选 AAAI 2026。它解决了通用时间序列模型难以捕捉金融数据高噪声、非平稳特性的问题，将 K 线序列视为金融市场的“语言”进行建模。

核心功能：支持基于 OHLCV（开高低收量）数据的多尺度预测，提供从 4.1M 到 499.2M 参数的四个模型版本（mini/small/base/large），并配有可视化实时演示（BTC/USDT 24 小时预测）。项目还开源了专用分词器（Kronos-Tokenizer）和微调脚本，方便用户适配自有任务。

适用场景：适合量化研究员、金融科技开发者、数据科学家用于市场趋势预测、交易信号生成、风险建模等任务。尤其适用于需要处理多交易所（超 45 家）异构 K 线数据、或希望基于预训练模型快速搭建金融预测系统的团队。

技术亮点：采用两阶段框架——先通过专用分词器将连续多维 K 线数据量化为分层离散 token，再用自回归 Transformer 预训练，这一设计有效应对了金融数据的噪声和跨市场差异。模型已开源至 Hugging Face，且论文发表于 arXiv，技术可复现性强。

上手建议：从安装依赖并运行 KronosPredictor 类开始，几分钟内即可完成首次预测。若要深入定制，建议先阅读 arXiv 论文理解 tokenizer 设计，再参考微调脚本适配自有数据；贡献者可关注 GitHub Issues 和待办事项，参与数据扩充或模型评测。

数据来源: github.com/trending

报告日期: 2026-08-03

由 DeepSeek AI 提供智能分析 | 自动生成