



GitHub Trending Top 10

每日热门开源项目深度解读

2026-09-24

今日榜单

1	rohitg00/ai-engineering-from-scratch Learn it. Build it. Ship it for others.	Python	NEW
2	vectorize-io/hindsight Hindsight: Agent Memory That Learns	Python	NEW
3	dream-num/univer The Office Harness for AI Agents — Spreadsheets, Docs, Slides, Canvas, Relationa...	TypeScript	3天
4	google/ax Google's open agentic orchestration runtime	Go	3天
5	NVIDIA/Model-Optimizer A unified library of SOTA model optimization techniques like quantization, disti...	Python	NEW
6	FxEmbed/FxEmbed Fix X/Twitter and Bluesky embeds! Use multiple images, videos, polls, translatio...	TypeScript	NEW
7	anthropics/financial-services	Python	5天
8	HKUDS/CLI-Anything "CLI-Anything: Making ALL Software Agent-Native" -- CLI-Hub:https://clianything....	Python	2天
9	mvt-project/mvt MVT (Mobile Verification Toolkit) helps with conducting forensics of mobile devi...	Python	NEW
10	obra/superpowers An agentic skills framework & software development methodology that works.	Shell	2天

#1

Python

NEW

ai-engineering-from-scratch

Learn it. Build it. Ship it for others.

Stars **56,063** Forks **9,887** Today **+310**

<https://github.com/rohitg00/ai-engineering-from-scratch>

项目简介：这是一个系统化的 AI 工程学习课程仓库，目标是让学习者从零开始、端到端地“亲手构建”AI 系统。它针对的核心痛点是：绝大多数学生已在用 AI 工具，却只有少数人具备专业级使用与构建能力，这个项目试图填补这道鸿沟。

核心功能：提供 523 节课、20 个阶段、约 342 小时的完整课程体系，覆盖 Python、TypeScript、Rust、Julia 多语言；每节课都产出可复用工件（prompt、skill、agent、MCP server）；按“你想构建什么”提供多条学习路径入口（如 LLM 应用、Agent、MCP、编码代理实战）；配套独立网站与 GitHub 双端同源课程；内置 12 种语言的翻译落地页。

适用场景：适合想系统入门 AI 工程的初学者、有 Python 基础想补数学与 ML 的开发者、以及准备构建生产级 LLM 应用或 Agent 的工程师。典型场景包括自学、课程教学、团队内训，以及按目标（如 MCP、Agent 工作台）定向深挖。

技术亮点：课程本身即工程实践，强调每课交付可复用产物而非纯理论；多语言技术栈覆盖广；采用 i18n 分支机制做课程翻译，英文为权威版本；网站统计数据由构建脚本自动生成，保证数据与内容同步。

上手建议：不要试图先扫完 523 节课，直接从 README 的“选择你想构建的目标”表格切入，按目标跳转到对应 Phase 或学习路径。建议先跑通 Phase 0 的环境配置，再根据兴趣选择 LLM 工程或 Agent 工程方向；贡献可从翻译、课程勘误或新增 MCP/Agent 案例入手。

#2

Python

NEW

hindsight

Hindsight: Agent Memory That Learns

Stars **27,103** Forks **2,556** Today **+1,607**

<https://github.com/vectorize-io/hindsight>

项目简介：Hindsight 是由 Vectorize.io 推出的 Agent 记忆系统，目标是让 AI Agent 不只是"记住"对话历史，而是能够"学习"并随时间进化。它针对 RAG 和知识图谱等传统方案在长期记忆任务上的不足，提供了在 LongMemEval 基准上达到 SOTA 表现的替代方案。

核心功能： - **三种核心操作：** retain（保留）、recall（召回）、reflect（反思），构成记忆的写入、检索与提炼闭环。 - **分层记忆结构：**支持 memory types、observations（观察）、mental models 与 knowledge pages，让 Agent 形成结构化的长期认知而非碎片化记录。 - **Memory Banks：**以"记忆银行"为单位组织不同上下文或用户的记忆，便于隔离与管理。 - **多形态接入：**提供 Docker 自托管服务、Python 嵌入式（无需服务器）、LLM Wrapper（2 行代码接入）、MCP Server 以及多种平台集成。

适用场景：适合构建需要长期陪伴或持续学习的 AI Agent 的开发者，例如个人助理、客服机器人、编程 Agent、教育辅导等需要跨会话记忆与个性化演进的场景。企业级用户（README 提到已有 Fortune 500 公司在生产环境使用）也可用于构建内部智能体平台。

技术亮点：一是以"学习"而非"检索"为核心设计理念，通过 reflect 和 observations 机制让记忆被主动提炼而非被动查询；二是兼容 25+ LLM 提供商（OpenAI、Anthropic、Gemini、Ollama 等），支持本地化部署；三是基准成绩由 Virginia Tech 和 Washington Post 独立复现，可信度较高；四是同时提供 Python 和 NPM 客户端，并有论文（arXiv:2512.12818）支撑。

上手建议：最快路径是用 Docker 一条命令启动服务（需配置 LLM API Key），然后通过 Python 或 NPM 客户端连接；若不想跑服务，可直接使用 Python 嵌入式模式。建议先阅读官方 Cookbook 和 Core Concepts 文档理解 retain/recall/reflect 模型，再参考 Integrations 页面接入现有 Agent 框架。想贡献代码可从 GitHub Issues 和 Slack 社区入手。

#3

TypeScript

连续 3 天

univer

The Office Harness for AI Agents — Spreadsheets, Docs, Slides, Canvas, Relational Tables, and PDF in one runtime.

Stars **17,189** Forks **1,500** Today **+1,060**

<https://github.com/dream-num/univer>

项目简介：Univer 是一个开源的 Office SDK，用 TypeScript 编写，目标是让开发者把电子表格、文档、演示文稿等办公能力嵌入到自己的产品里，而不是跳转到某个托管应用。它解决的核心问题是：市面上缺少一套高性能、可深度定制、且浏览器与 Node.js 共用同一架构的办公套件底层框架。从定位看，它正在把自己包装成“AI Agent 的 Office 运行时”，让人类和 AI 能在同一份文件里协作。

核心功能：一是多品类办公能力，覆盖表格、文档、幻灯片、关系型表格、看板，PDF 也在路线图中；二是插件化架构，开发者可以按需组合功能，也可以直接用预设快速起步；三是统一的 Facade API，同一套接口在浏览器和 Node.js 上都能跑，便于服务端处理工作簿和文档；四是内置公式引擎和基于 Canvas 的渲染，性能与自定义能力兼顾；五是支持自定义插件、命令、服务、UI 组件来扩展行为。

适用场景：适合需要在 SaaS 产品、内部工具、BI 流程或 AI 应用中嵌入表格/文档编辑能力的团队。典型用法包括：在业务系统里做在线表格协作、在服务端批量处理工作簿、为 AI Agent 提供可读写的 Office 文件环境，以及基于 Univer Workspace 这类参考实现搭建自托管协作空间。

技术亮点：最值得关注的是“一套运行时、多种 Office 工具”的架构——存储和计算共享，内容可以跨工具组合嵌入，链接数据和引用能同步更新。Canvas 渲染加公式引擎的组合，让它在性能和可定制性上比传统 DOM 方案更有空间。插件架构配合 Facade API，既保证了扩展性，又降低了跨端（浏览器/Node.js）的接入成本。

上手建议：建议先从官网文档和 API Reference 入手，跑通一个最小嵌入示例，再根据需求选择预设或按插件裁剪。想深入的话，可以研究 Univer Workspace 这个开源参考实现，看它如何集成 SDK 并绑定单元格与页面控件。贡献方面，项目有 Discord 社区和 GitHub Issues，适合从插件、UI 组件或文档改进切入；如果关注 AI Agent 方向，可以重点跟进其“人与 Agent 同文件协作”的能力演进。

#4

Go

连续 3 天

ax

Google's open agentic orchestration runtime

Stars **9,835** Forks **485** Today **+1,376**

<https://github.com/google/ax>

项目简介：AX 是 Google 开源的一个"智能体编排运行时"（Agentic Orchestration Runtime），用 Go 编写。它把 AI Agent 当作一种全新的工作负载来对待——既不是无状态微服务，也不是一次性的批处理任务，而是需要隔离、需要状态、需要网络管控、还可能"烧钱"的持久化实体。AX 的目标是在集群中大规模（号称单集群可跑数十亿任务）地声明式管理和运行这些 Agent。

核心功能：

- 四个声明式原语：**Task（隔离沙箱中运行 Agent 代码，带 CPU/内存限制）、Workspace（预置 Git 仓库、MCP 服务器、技能包，让 Agent 一启动就"热"）、Gateway（把出站流量锁死到显式主机白名单）、Model（配置平台使用的 LLM 及凭据）。
- 全生命周期管理：**通过 `ax apply/get/watch/ssh/suspend/resume` 等命令，支持实时观察、进入沙箱调试、暂停与断点续跑。
- Kubernetes 式交互体验：**所有配置都是 `ax.io/v1alpha1` 的 YAML manifest，一条命令即可应用，熟悉 `kubectl` 的人几乎零学习成本。

适用场景：需要大规模、安全地运行自主 AI Agent 的团队——尤其是那些让 Agent 执行不可信代码、访问外部模型 API 和工具服务器、又担心失控或成本爆炸的场景。也适合想要给 Agent 建立标准化"运行底座"的平台工程团队。

技术亮点：

- **分层架构：**底层依赖 Agent Substrate 做沙箱执行，上层是声明式控制平面，职责清晰。
- **网络围栏（Gateway）：**通过显式主机白名单限制 Agent 出站流量，这是 Agent 安全的关键设计。
- **状态可暂停/恢复：**`suspend/resume` 让空闲 Agent 可以 checkpoint 后暂停，再精确续跑，兼顾成本与状态连续性。
- **面向规模设计：**明确以"单集群数十亿任务"为吞吐目标，走的是高吞吐编排路线。

上手建议：

- **使用者：**先装 CLI (`go install github.com/google/ax/cmd/ax@latest`)，准备一个 K8s 集群和 ko，用 `make deploy` 部署控制平面到 `ax-system` 命名空间，再跑 `examples/task.yaml` 或 `./demo.sh` 体验完整生命周期。
- **贡献者：**先精读 `docs/concepts.md` 和 `DESIGN.md` 理解核心概念与 API，再参考 `docs/runner.md` 了解控制平面与任务容器的契约。
- **注意：**项目明确警告仍处于早期，核心概念和协议可能发生重大破坏性变更，不建议用于生产关键路径。

#5

Python

NEW

Model-Optimizer

A unified library of SOTA model optimization techniques like quantization, distillation, pruning, neural architecture search, speculative decoding, etc. It compresses deep learning models for downstream deployment frameworks like TensorRT-LLM, TensorRT, vLLM, etc. to optimize inference speed.

Stars **3,920** Forks **624** Today **+22**

<https://github.com/NVIDIA/Model-Optimizer>

项目简介：NVIDIA Model Optimizer (ModelOpt) 是 NVIDIA 开源的一套统一模型优化库，目标是把深度学习模型“压小、压快”，同时尽量不损失精度。它解决的是大模型部署时显存占用高、推理速度慢的核心痛点，让训练好的模型能高效跑在 TensorRT-LLM、vLLM、SGLang 等下游推理框架上。

核心功能：一是量化，覆盖 PTQ、QAT 以及 NVFP4/FP8 等低精度格式，是项目最核心的能力；二是剪枝与蒸馏，包括 Minitron、Puzzletron 等结构化压缩方案；三是投机解码、稀疏化和神经架构搜索 (NAS) 等加速技术。此外还提供统一的 Hugging Face 导出 API，支持 transformers 和 diffusers 模型，一键产出可直接部署的量化 checkpoint。

适用场景：主要面向需要把大模型（尤其是 LLM 和 VLM）部署到生产环境的团队，比如想在有限 GPU 上提升吞吐、降低显存成本，或需要发布官方量化版本（如 Nemotron 系列的 FP8/NVFP4 checkpoint）的场景。也适合做模型压缩研究的开发者，借助其与 Megatron-LM、Hugging Face Accelerate 的集成在训练流程中直接做量化感知优化。

技术亮点：一是“训练—优化—部署”全链路打通，量化产物能无缝对接 NVIDIA AI 软件生态，工程落地性强；二是算法前沿，近期博客涉及 Local-Hessian 权重缩放、AutoQuantize 自动混合精度分配、QAD（量化感知蒸馏）等 SOTA 方法；三是生态联动深，与 Megatron-Bridge、TensorRT-LLM 等深度集成，并有 Nemotron、Colosseum、Bielik 等真实大模型压缩案例背书。

上手建议：建议先从官方文档 (nvidia.github.io/Model-Optimizer) 和 PyPI 安装 `nvidia-modelopt` 入手，跑通一个量化示例，再对照 README 中的端到端 tutorial（如 Qwen3.6、Nemotron-3-Nano）理解完整流程。想贡献代码可先看 Roadmap (issue #1699) 了解方向，从文档完善或示例补充等低门槛任务切入，同时熟悉其量化 API 与导出接口的设计约定。

#6

TypeScript

NEW

FxEmbed

Fix X/Twitter and Bluesky embeds! Use multiple images, videos, polls, translations and more on Discord, Telegram and others

Stars **5,290** Forks **245** Today **+165**

<https://github.com/FxEmbed/FxEmbed>

项目简介：FxEmbed 是一个修复 X/Twitter 和 Bluesky 链接嵌入效果的开源服务，本质上是把原本残缺的推文预览变成包含视频、投票、翻译、引用等完整内容的富媒体卡片。它通过简单的域名替换技巧（如把 x.com 改成 fixupx.com）即可生效，无需安装任何插件。

核心功能：一是多图/视频/投票的完整嵌入展示，让 Discord、Telegram 等平台不再只显示干巴巴的链接；二是内置翻译功能，可自动翻译推文内容；三是支持引用推文的嵌套展示；四是提供 API 接口，方便开发者集成；五是通过 Mosaic 组件实现多图拼接合并。

适用场景：主要面向在 Discord、Telegram 等聊天平台频繁分享推特/Bluesky 链接的用户群体，尤其是需要展示完整推文内容的社区运营者、内容创作者和普通用户。也可以作为开发者自建嵌入服务的参考实现。

技术亮点：项目基于 Cloudflare Worker 运行，采用 TypeScript 编写，通过 Host 头进行路由分发，架构轻量且边缘部署友好。Docker 镜像使用 Wrangler 本地运行时而非传统 Node.js 服务器，体现了 Serverless 优先的设计思路；同时通过 Crowdin 支持社区多语言翻译。

上手建议：普通用户直接使用官方域名替换技巧即可，无需部署；开发者想自托管可参考文档的部署指南，从复制 .env.example 和 wrangler.example.toml 开始，用 Docker Compose 一键启动。想贡献代码可从 GitHub Issues 入手，翻译工作则可通过 Crowdin 平台参与。

#7

Python

连续 5 天

financial-services

Stars **37,236** Forks **5,411** Today **+510**<https://github.com/anthropics/financial-services>

项目简介：这是 Anthropic 官方推出的金融服务行业 AI 智能体参考实现库，为投资银行、股票研究、私募股权和财富管理等场景提供开箱即用的 Claude 智能体、技能包和数据连接器。它解决的核心问题是：把大模型能力落地到高度专业化、强合规的金融 workflows 中，让机构不必从零搭建。

核心功能：提供十余个命名智能体（如 Pitch Agent 生成路演材料、Model Builder 在 Excel 中搭建 DCF/LBO 模型、GL Reconciler 做总账对账、KYC Screener 做开户审查）；按垂直行业打包的技能与斜杠命令（/comps、/dcf、/earnings）；MCP 数据连接器；以及合作方（LSEG、S&P Global）构建的插件。

适用场景：投行分析师做可比公司分析和推介材料、股票研究员整理财报电话会并更新模型、私募做估值复核与 LP 报告、基金财务运营做月末结账与对账、合规团队做 KYC 筛查。所有输出都定位为"待人工签署的初稿"，而非自动决策。

技术亮点：一是"一份源码、两种部署"——同一套系统提示词和技能既可作 Cework 插件安装，也可通过 Managed Agents API 部署到自有 workflow 引擎；二是每个智能体自包含，打包了所需技能，安装即用；三是明确的人机边界设计，智能体只起草、不执行交易、不入账、不批准，合规意识内建于架构。

上手建议：最快路径是在 Claude Code 中 `claude plugin marketplace add anthropics/financial-services`，先装 financial-analysis 核心技能包，再按需安装具体智能体。想深入定制或做工程贡献，可从 `managed-agent-cookbooks/` 和 `scripts/` 目录入手，研究 `agent.yaml` 结构、子智能体设计和部署脚本，再基于自身机构的流程调整提示词与连接器。

#8

Python

连续 2 天

CLI-Anything

"CLI-Anything: Making ALL Software Agent-Native" -- CLI-Hub:<https://clianything.cc/>

Stars **50,184** Forks **4,610** Today **+415**

<https://github.com/HKUDS/CLI-Anything>

项目简介：CLI-Anything 是香港大学数据科学实验室（HKUDS）推出的开源项目，目标是把所有软件都变成"Agent-Native"——即为各类软件自动生成或封装命令行接口（CLI），让 AI Agent 能够像人类使用 GUI 一样去操作这些软件。它解决的核心痛点是：AI Agent 擅长调用命令行，但大量软件只有图形界面或私有 API，无法被 Agent 直接驱动。

核心功能：一是为各类软件生成标准化的 CLI 封装（harness），让 Agent 可通过命令行调用；二是提供 CLI-Hub 社区仓库，用户可 `pip install cli-anything-hub` 后用 `cli-hub install <name>` 一键浏览、安装、管理社区贡献的 CLI；三是支持 preview、live preview 和 trajectory loop 等机制，让 Agent 能预览结果并迭代操作，产出 CAD 建模、3D 场景、图表、字幕等真实产物；四是提供 JSON + 人类可读双格式输出，便于 Agent 解析；五是配套 2461 个测试和 arXiv 技术报告，保证可靠性。

适用场景：主要面向 AI Agent 开发者、自动化工程师和希望让 Agent 操控专业软件（如 CAD、GIS、设计工具）的团队。典型场景包括：让 Cursor、Claude Code 等编码 Agent 直接驱动桌面软件完成任务；为缺乏 API 的行业软件搭建 Agent 操作层；以及社区开发者为自己熟悉的软件贡献 CLI harness。

技术亮点：基于 Python 3.10+ 和 Click 框架构建，强调 100% pytest 通过率和单元+端到端覆盖；采用"harness"抽象层统一不同软件的调用方式，配合 trajectory loop 实现 Agent 的闭环操作与自我修正；同时通过 CLI-Hub 实现了去中心化的社区贡献与即时分发机制，PR 合并后 hub 立即更新。

上手建议：最快路径是先 `pip install cli-anything-hub`，再 `cli-hub install <name>` 安装现成 CLI 试用；想深入可阅读 README 的 Quick Start 和 arXiv 技术报告。若想贡献，可通过 CONTRIBUTING.md 提交自己的 CLI harness，或在 issues 中提交 wishlist 请求希望支持的软件；项目还提供中文文档，对中文开发者友好。

#9

Python

NEW

mvt

MVT (Mobile Verification Toolkit) helps with conducting forensics of mobile devices in order to find signs of a potential compromise.

Stars **14,626** Forks **1,390** Today **+275**

<https://github.com/mvt-project/mvt>

项目简介：MVT (Mobile Verification Toolkit) 是由 Amnesty International 安全实验室开发的一套移动设备取证工具集，用于检测 Android 和 iOS 设备是否被 Pegasus 等商业间谍软件感染。它诞生于 2021 年“飞马计划”调查背景下，将原本复杂的取证流程自动化、命令行化。

核心功能： - 支持 iOS 备份和 Android 设备的取证数据采集与解析，提取短信、通话记录、浏览器历史、进程列表等痕迹。 - 基于公开的 IOC（入侵指标）库扫描设备，匹配已知间谍软件的感染特征。 - 提供 mvt-ios、mvt-android 和 mvt 三个命令，覆盖备份检查、APK 分析、IOC 下载等操作。 - 支持插件机制，可通过插件包扩展额外的取证模块和顶层命令。

适用场景：主要面向数字取证研究人员、记者、人权工作者和安全调查人员，用于对可能被定向监控的高风险人群设备进行取证分析。普通用户不建议自行使用，README 明确强调这不是自助安全评估工具，怀疑设备被入侵应寻求专业协助。

技术亮点：项目将 iOS 备份解析、Android 系统痕迹提取与 IOC 匹配整合为统一 CLI 工作流，降低了取证门槛；v3 版本引入破坏性变更并重构了命令体系（如 --verbose 位置调整、shell completion 支持），同时通过插件架构保持扩展性。其 IOC 库独立维护，便于快速响应新披露的间谍软件 campaign。

上手建议：先阅读官方文档（docs.mvt.re）了解安装依赖和取证方法论文档，通过 `pip3 install mvt` 或 `uv tool install mvt` 安装后，从 `mvt-ios check-backup` 或 `mvt-android check-adb` 等基础命令入手。贡献方面可关注 GitHub Issues 中的插件开发和 IOC 更新需求，注意 v3 的破坏性变更说明（issue #757）以避免脚本兼容问题。

#10

Shell

连续 2 天

superpowers

An agentic skills framework & software development methodology that works.

Stars **291,033** Forks **26,038** Today **+606**

<https://github.com/obra/superpowers>

项目简介：Superpowers 是一套面向 AI 编码代理（coding agent）的“软件开发方法论 + 技能框架”，由 obra 开发。它解决的问题是：AI 代理往往一上来就写代码，容易跑偏、缺乏规划、质量不可控。Superpowers 通过可组合的技能（skills）和自动触发的指令，让代理先理解需求、再规划、最后按 TDD 流程执行。

核心功能： 1. **需求澄清与规格化：**代理不会立即编码，而是先反问用户真正想做什么，并把需求拆成可读的小块供确认。 2. **实现计划生成：**在设计签核后，输出一份“连初级工程师都能照做”的详细计划，强调 TDD、YAGNI、DRY。 3. **子代理驱动开发：**启动 subagent-driven-development，让多个代理分头执行任务并互相审查，可自主工作数小时不偏离计划。 4. **跨工具兼容：**支持 Claude Code、Cursor、Codex、Gemini CLI、Copilot CLI 等十余种主流编码代理平台。 5. **自动触发：**技能自动生效，用户无需额外操作，装上即拥有“超能力”。

适用场景： - 使用 AI 编码代理进行中大型项目开发的个人开发者或团队。 - 希望让 AI 代理从“乱写代码”转向“按方法论规范开发”的工程团队。 - 企业环境中需要商业支持、额外工具或托管支出的用户（README 提供了 sales@primeradiant.com 联系渠道）。

技术亮点： - 以 Shell 为主要语言，通过插件/扩展机制深度集成到各代理平台（如 Claude 插件市场、Gemini extensions、Droid marketplace）。 - 核心是“可组合技能”架构，技能可自动触发并串联成完整开发流程。 - 引入 subagent 协作模式，让代理之间互相检查，提升自主开发的可靠性。

上手建议： - 先根据你使用的代理平台，按 README 对应章节安装（如 Claude Code 用 `/plugin install superpowers@claude-plugins-official`）。 - 从“The Basic Workflow”和“Philosophy”两节理解其方法论，再跑一个小项目体验自动触发效果。 - 想贡献可先阅读“Contributing”和“What's Inside”，了解技能结构后再提交新技能或改进。

数据来源: github.com/trending

报告日期: 2026-09-24

由 DeepSeek AI 提供智能分析 | 自动生成