GitHub Trending Top 10

每日热门开源项目深度解读

2026-10-12

今日榜单

1 **morluto/rea** TypeScript
Reverse engineer anything with agents, from app behavior down to native binaries... 7天

2 **bilawalsidhu/gods-eye-view** JavaScript
A spy satellite simulator in your browser, except the data is real. Live open so... 2天

3 **mksglu/context-mode** TypeScript
Context window optimization for AI coding agents. Sandboxes tool output (98% red... NEW

4 **storytold/artcraft** Rust
ArtCraft is an intentional crafting engine for artists, designers, and filmmaker... 5天

5 **open-webui/open-webui** Python
User-friendly AI Interface (Supports Ollama, OpenAI API, ...) NEW

6 **cathrynlavery/diagram-design** HTML
Editorial diagram design for Claude Code, Codex, GitHub Copilot, Cursor, Factory... 6天

7 **lyogavin/airllm** Jupyter Notebook
AirLLM 70B inference with single 4GB GPU 2天

8 **microsoft/BitNet** C++
Official inference framework for 1-bit LLMs NEW

9 **Alishahryar1/free-claude-code** Python
Use Claude Code, Codex, VSCode, Pi, and OpenCode (and 6 other harnesses) for fre... NEW

#1 TypeScript 连续 7 天

rea

Reverse engineer anything with agents, from app behavior down to native binaries.

Stars **147,911** Forks **34,273** Today **+45,495**

https://github.com/morluto/rea

项目简介：REA 是一个基于 MCP（Model Context Protocol）的逆向工程工具，让 AI Agent 能够"看懂"任意软件的内部实现——从应用行为一路深入到原生二进制层面。它解决的核心问题是：当你看到一个喜欢的功能却拿不到源码时，可以让 Agent 帮你分析其工作原理并复刻出来。

核心功能：一是通过统一的 MCP 接口连接多种分析工具，覆盖原生二进制、JavaScript/Electron 应用、.NET 程序集和网站；二是静态分析 JavaScript/Electron 应用，无需原生分析引擎即可提取模块、导入关系和 Electron 边界；三是可对接 Hopper、Ghidra、IDA 等现有反汇编工具进行原生二进制分析；四是所有分析在本地运行，并附带证据链和局限性说明，保证结论可追溯。

适用场景：主要面向逆向工程师、安全研究人员和想研究竞品实现的产品开发者。典型用法是让 Agent 分析某个 App 的特定功能（如搜索机制），理解其实现思路后在自己的项目中构建类似功能，也可直接在终端中调用 CLI 进行脚本化分析。

技术亮点：用 TypeScript 实现，以 MCP 协议为核心将逆向工具"Agent 化"，让大模型能够直接驱动专业的二进制分析工具；强调"证据驱动"，每个结论都附带证据和局限说明，避免 AI 幻觉；分析全程本地执行，兼顾隐私与安全；一条 `npx rea-agents setup` 即可自动注册到 Claude Code、Cursor、Codex 等主流 Agent。

上手建议：确保已安装 Node.js 和 npm，直接运行 `npx rea-agents setup` 选择你的 Agent 并批准配置变更，重启后即可用自然语言提问。想深入命令行的话，可先试用 `analyze-javascript-application` 分析一个 Electron 应用，再根据需要配置 Hopper/Ghidra 等原生分析后端；贡献者可参考仓库中的 CLI 与 Evidence 指南及 MCP 合约文档。

#2 JavaScript 连续 2 天

gods-eye-view

A spy satellite simulator in your browser, except the data is real. Live open source spatial intelligence on a photorealistic 3D globe.

Stars **53,291** Forks **10,575** Today **+1,903**

https://github.com/bilawalsidhu/gods-eye-view

项目简介：God's Eye View 是一个运行在浏览器里的“间谍卫星模拟器”，把航班应答机、船舶信标、卫星轨道、地震仪、公共摄像头等公开数据源聚合到一个照片级写实的 3D 地球上。它解决的问题是——这些公开信号本已存在，却散落各处，它让用户能在全球态势与单个飞机、船只、街景之间自由切换，全部本地运行、代码可查。

核心功能： - **点击追踪一切**：锁定任意飞机/船只/火点，自动绘制渐隐轨迹、展示完整元数据，并能一键跳转到最近的实时摄像头。 - **座舱视角与 3D 机库**：可“坐进”被追踪航班内部，跟随地形飞行，接近时目标从图标切换为真实机型模型（787、MQ-9 等）。 - **实时语音控制**：由实时 AI agent 驱动，可用语音提问卫星过境时间、添加标注、重置地球。 - **传感器视觉滤镜**：用 GLSL 渲染 CRT、夜视、FLIR 热成像、Noir 等风格，叠加检测框与军用 HUD。 - **多源实时图层**：天气（GFS/ECMWF、雷达、闪电）、飓风路径、ALPR 摄像头位置、卫星过境预报等，多数无需 API key。

适用场景：适合对开源情报（OSINT）、地理空间数据、航空/航运追踪感兴趣的开发者与研究者；也适合内容创作者做演示视频、教育者讲解卫星与传感数据、以及任何想直观感受“公开数据能拼出什么”的普通用户。

技术亮点：纯 JavaScript 前端，核心是把异构实时数据流统一映射到同一个 3D 地球坐标系；每个数据图层是独立模块，便于扩展；GLSL 着色器实现多种传感器视觉风格；语音交互接入实时 AI agent；URL 可序列化相机、图层与追踪目标，实现“活的分享链接”而非静态书签。

上手建议：无需 API key 即可启动，推荐用 Pinokio 一键安装或从终端本地运行，先体验“最初五分钟”教程；想贡献可从新增一个数据图层模块入手，README 明确说明每层都是独立模块，扩展门槛较低。

#3 TypeScript NEW

context-mode

Context window optimization for AI coding agents. Sandboxes tool output (98% reduction), persists session memory, and enforces routing across 17 platforms via MCP + hooks.

Stars **27,129** Forks **1,938** Today **+394**

https://github.com/mksglu/context-mode

项目简介：Context Mode 是一个面向 AI 编程代理（AI Coding Agent）的 MCP 服务器，专门解决"上下文窗口"被工具输出快速填满的问题。它通过沙箱化工具返回结果、持久化会话记忆、以及跨平台路由，让代理在长时间编码会话中保持"记得住、不卡壳"。

核心功能：1. **上下文节省（Context Saving）**：把 Playwright 快照、GitHub issue、日志等原始工具输出隔离在上下文窗口之外，宣称可将 315 KB 压缩到 5.4 KB，减少约 98%。 2. **会话连续性（Session Continuity）**：将文件编辑、git 操作、任务、错误、用户决策等事件写入 SQLite，并用 FTS5 + BM25 做检索，压缩对话后只把相关内容拉回上下文，避免"失忆"。 3. **代码化思考（Think in Code）**：鼓励 LLM 在代码环境中推理，而不是把冗长解释塞进自然语言上下文，从输入端和输出端同时节省 token。 4. **跨平台路由**：通过 MCP + hooks 支持 17 个平台的路由与集成。 5. **会话隔离**：不加 `--continue` 时旧会话数据立即删除，保证新会话从干净状态开始。

适用场景：- 使用 Claude Code、Cursor、各类 MCP 兼容 IDE/Agent 的开发者，尤其是做多文件重构、长时间结对编程、频繁调用外部工具（如 Playwright、GitHub API）的场景。 - 团队协作中希望代理能跨会话保留关键决策和任务状态，又不想被历史数据淹没的工程团队。

技术亮点：- 将"上下文管理"拆成四层问题（工具输出、会话记忆、输入冗余、输出冗余），而不是简单做截断。 - 用 SQLite + FTS5 + BM25 做事件索引与按需检索，而不是把历史全量塞回上下文，是"检索增强记忆"在 Agent 场景的落地。 - 通过 MCP 标准化协议 + hooks 实现跨平台兼容，避免为每个 IDE 单独适配。 - 采用 ELv2 许可证，商业使用需注意条款。

上手建议：- 从 npm 安装 `context-mode`，按 README 配置到你的 MCP 客户端（如 Claude Code、Cursor），先在一个小项目里观察上下文占用和会话恢复效果。 - 想贡献代码，可先阅读仓库中 MCP server 与 SQLite/FTS5 索引部分的实现，重点关注 hooks 路由层；遇到问题可加入其 Discord 社区讨论。

#4 Rust 连续 5 天

artcraft

ArtCraft is an intentional crafting engine for artists, designers, and filmmakers

Stars **21,154** Forks **3,439** Today **+4,106**

https://github.com/storytold/artcraft

项目简介：ArtCraft 是一个面向艺术家、设计师和影视创作者的「AI 图像与视频创作 IDE」，由 Rust 编写。它试图解决当前 AI 生成工具"只能靠提示词碰运气"的核心痛点——把生成式 AI 从"打字抽卡"变成可控、可复现的创作流程。项目今日新增 4106 星，总星标已超 2.1 万，热度极高。

核心功能： - **2D/3D 场景合成**：支持图层合成、背景去除、绘制工具，以及在 3D 空间中分层摆放背景、前景与道具，构建有纵深感的构图。 - **Image to Location**：把虚拟角色放入一致的环境中，方便在同一场景里规划多个镜头，保证镜头间的空间连贯性。 - **Image to 3D Mesh**：将一张图片转成可定位、旋转、取景的 3D 物体，让静态素材进入可编辑的三维空间。 - **角色摆姿与相机预演**：在生成最终画面之前，先摆好角色姿势、定好机位，实现"先搭场景再生成"。 - **Kitbashing 场景布局**：组合 3D 素材套件来控制机位角度、物体位置与景深。

适用场景：主要面向需要精确控制画面构图的内容创作者——分镜师、概念设计师、独立动画/短片制作者，以及做 AI 视频、漫画、游戏预演的团队。典型用法是：先在一个虚拟"摄影棚"里搭好场景和角色，规划好多个镜头，再调用不同生成模型出图/出片，从而保证角色一致性和镜头可复现。

技术亮点：用 Rust 构建桌面级创意工具，兼顾性能与跨平台；核心思路是把"提示词"升级为"可视化工艺"（crafting），通过 2D/3D 场景图 + 相机系统 + 可插拔模型（"choose the models that fit your work"）把生成过程结构化、可重复。这种"先布局、后生成"的架构，本质上是在给扩散模型套上一层确定性的空间控制层。

上手建议：普通用户可直接从官网 getartcraft.com 下载安装包，或看官方两分钟 YouTube 演示快速了解工作流；开发者可参考仓库内 `_docs/dev_setup.md` 从源码构建（需 Rust 环境）。想深入参与可加入其 Discord 社区，关注 issue 区（如 README 中提到的媒体展示 issue #1951）了解当前开发重点。由于项目处于早期高热度阶段，建议先跑通 demo 再决定贡献方向。

#5 Python NEW

open-webui

User-friendly AI Interface (Supports Ollama, OpenAI API, ...)

Stars **154,791** Forks **22,630** Today **+142**

https://github.com/open-webui/open-webui

项目简介：Open WebUI 是一个可自托管、完全离线运行的 AI 交互平台，定位为“AI 的家”。它解决了用户在不同大模型提供商之间切换时缺乏统一、友好界面的问题，同时兼顾数据主权与隐私需求。

核心功能：支持 Ollama 及任意 OpenAI 兼容 API（如 LMStudio、GroqCloud、vLLM 等），实现多模型自由混用；提供插件系统（Filters、Actions、Pipes、Tools 等）与 MCP/OpenAPI 工具集成，可扩展外部服务；内置 RBAC 权限与用户组管理，支持模型/代理级别的细粒度访问控制；集成持久记忆、频道协作、日历调度与自动化任务等团队协作能力。

适用场景：适合希望私有化部署 AI 能力的个人开发者、中小企业及对数据合规有要求的团队。典型场景包括：本地运行开源模型聊天、统一接入多家云模型 API、构建内部 AI 助手平台、以及需要多用户权限隔离的团队协作环境。

技术亮点：后端以 Python 为主，前端支持 PWA 离线访问，部署方式覆盖 pip、Docker、Kubernetes 等多种形态。插件架构设计灵活，支持动态变量、审批流与速率限制；Open Terminal 为代理提供终端与文件系统能力，实现多步任务自动化执行。

上手建议：最快路径是用 Docker 拉取 `:ollama` 或 `:cuda` 镜像一键启动，配合本地 Ollama 即可体验。想深入定制可查阅官方文档的插件开发章节，从编写一个简单的 Filter 或 Tool 入手；贡献代码前建议先加入 Discord 社区了解当前开发重点与 issue 标签。

#6 HTML 连续 6 天

diagram-design

Editorial diagram design for Claude Code, Codex, GitHub Copilot, Cursor, Factory Droid, and Pi. 44 diagram types. Self-contained HTML + SVG. No shadows. No Mermaid slop.

Stars **52,307** Forks **3,300** Today **+2,100**

https://github.com/cathrynlavery/diagram-design

项目简介：这是一个面向 AI 编程代理（Agent Skill）的图表设计技能包，让 Claude Code、Cursor、Copilot 等工具能按你的品牌风格直接生成"编辑级"的图表。它解决的是 AI 生成图表普遍难看的问题——用作者的话说，就是拒绝"没有阴影、拒绝 Mermaid 式粗制滥造"，输出更接近设计师手笔的成品。

核心功能： - 支持 44 种图表类型（架构图、象限图、时序图等），用自然语言描述即可生成。 - 输出为单一自包含的 HTML + SVG 文件，双击即可打开，无需依赖或构建。 - 品牌适配：可通过 `Onboard diagram-design to https://yoursite.com` 自动抓取你网站的配色和字体，让所有图表风格统一。 - 支持从 draw.io、Mermaid、Excalidraw 导入，并可导出 PNG / SVG。 - 通过 `npx skills add` 一行命令安装，兼容 Cursor、Claude Code、Codex、Gemini CLI、Cline、Windsurf 等主流 Agent 宿主。

适用场景：适合需要频繁产出技术图表但不想手动调格式的开发者、技术写作者和产品经理。典型场景包括写架构文档、做项目优先级象限图、画 API 时序图，或在演示和 README 中嵌入风格统一的图示——尤其适合对图表美观度有要求、又不想学专业设计工具的人。

技术亮点：把"设计规范"封装成 Agent Skill，让 AI 代理按固定美学标准（无阴影、编辑级排版）产出 SVG，而非让模型自由发挥；输出完全自包含，规避了外部依赖和渲染环境差异；还提供了跨宿主的 skills CLI 与符号链接安装方案，一次更新可同步到多个编辑器。

上手建议：最简路径是运行 `npx skills add cathrynlavery/diagram-design`，然后在代理里用一句自然语言描述想要的图即可。想深入定制，可先跑一次品牌 onboard 命令拉取自己的配色字体；想贡献代码，建议先读 `skills/diagram-design/SKILL.md` 了解技能结构，再从新增图表类型或改进渲染脚本入手。

#7 Jupyter Notebook 连续 2 天

airllm

AirLLM 70B inference with single 4GB GPU

Stars **37,361** Forks **3,859** Today **+886**

https://github.com/lyogavin/airllm

项目简介

AirLLM 是一个专注于**大幅降低大语言模型推理显存占用**的开源项目，它让 70B 甚至 2.8T 级别的超大模型能够在单张 4GB 显存的消费级 GPU 上运行。与量化、蒸馏、剪枝等传统压缩手段不同，AirLLM 声称在**不损失模型精度**的前提下实现这一目标，本质上是通过分层流式加载与调度来"以小显存跑大模型"。

核心功能

1. **超大模型单卡推理**：支持 Llama 3.1 405B、DeepSeek-V3 671B、Kimi K3 2.8T 等旗舰模型，显存需求低至 3~12GB。
2. **统一 AutoModel 接口**：自动识别模型类型，无需手动指定模型类，兼容 Qwen、Llama、DeepSeek、Phi、Gemma、ChatGLM 等主流架构。
3. **量化与精度选项**：支持 8bit/4bit 量化、FP8 模型，以及 safetensors 格式。
4. **小显存训练支持**：通过逐层流式加载冻结权重、适配器常驻 GPU，实现 125B 模型在 6GB 显存下训练。
5. **跨平台支持**：除 CUDA GPU 外，还支持 CPU 推理和 MacOS 运行 70B 模型。

适用场景

主要面向**显存受限的个人开发者、研究者和学生**——手头只有一张 4GB 或 8GB 的消费级显卡，却希望本地跑通大模型做实验或应用开发。也适合**需要在单卡上验证超大模型行为**（如 MoE 路由、长上下文表现）的工程团队，作为低成本原型验证手段。

技术亮点

核心思路是**分层流式推理（layer-by-layer streaming）**：将模型权重按层切分存储，推理时逐层从磁盘/内存加载到 GPU，算完即释放，从而把峰值显存压到单层级别。针对 MoE 架构（如 Kimi K3）进

一步做了**按专家路由的流式加载**，只加载 token 实际激活的专家。此外还引入了**预取（prefetching）**让权重加载与计算重叠，缓解 I/O 瓶颈。

上手建议

从 `pip install airllm` 开始，直接参考 README 的 Quickstart 和 `air_llm/examples/` 下的 Jupyter Notebook（如 `run_llama3.1_405B.ipynb`）跑通第一个例子。注意提前准备**足够的磁盘空间**存放切分后的权重（部分模型需数百 GB），并留意不同模型对 `transformers` 版本、CUDA 版本和 flash-attn 的具体要求。想贡献的话，可以从新增模型适配、优化流式调度性能或补充文档测试入手。

#8 C++ NEW

BitNet

Official inference framework for 1-bit LLMs

Stars **40,839** Forks **3,804** Today **+134**

https://github.com/microsoft/BitNet

项目简介：BitNet.cpp 是微软官方推出的 1-bit LLM（如 BitNet b1.58）推理框架，旨在让极低位宽的大模型能在普通 CPU 上高效、无损地运行。它解决了传统 LLM 推理对高端 GPU 依赖过重的问题，把"大模型跑在消费级硬件上"变成现实。

核心功能：提供针对 1.58-bit 模型优化的 CPU/GPU 推理内核，支持快速且无损的推理；实现跨 ARM 与 x86 平台的加速（x86 最高 6.17x，ARM 最高 5.07x）；显著降低能耗（最高减少 82.2%）；支持单 CPU 运行 100B 参数模型，达到 5-7 tokens/秒的类人阅读速度；近期还扩展到嵌入模型（BitNet-embedding）和实时语音识别（VibeASR.cpp）。

适用场景：适合在边缘设备、笔记本、无 GPU 服务器上部署 LLM 的开发者与研究者；也适合关注能耗与成本的推理服务团队，以及想复现 1-bit LLM 研究的学术人员。典型场景包括本地离线推理、低功耗边缘 AI、以及嵌入式/端侧智能应用。

技术亮点：核心在于对三值权重（-1/0/1）的专用内核设计，配合 I2_S 量化与可配置分块（tiling）实现高效并行；通过系统级优化在保持精度的同时大幅提速降耗，并有配套论文（arXiv 2502.11880）支撑；从 CPU 扩展到 GPU 内核、再到 NPU 的路线图，显示出清晰的硬件适配战略。

上手建议：建议先从 README 的 "Build from Source" 在本地 CPU 上编译运行，或直接体验官方在线 Demo 快速感受效果；随后可参考 Hugging Face 上的 BitNet b1.58-2B-4T 模型与 I2_S 转换指南。想贡献代码可重点关注 `src/`（CPU 内核）和 `gpu/` 目录，从优化内核或补充文档入手门槛较低。

#9 Python NEW

free-claude-code

Use Claude Code, Codex, VSCode, Pi, and OpenCode (and 6 other harnesses) for free (1.3B+ free tokens) from your terminal, app, IDE, or phone, and now from the browser with native browser sessions (multi-harness + multi-model) like OpenClaw (voice supported + ToS friendly)

Stars **58,825** Forks **9,289** Today **+705**

https://github.com/Alishahryar1/free-claude-code

项目简介：Free Claude Code（FCC）是一个独立的开源工具，核心目标是让用户通过聚合 61 家服务商的免费额度（宣称每月 1.3B+ tokens），免费使用 Claude Code、Codex、OpenCode 等 11 种编码 Agent。它解决的是 AI 编程工具订阅成本高、单一服务商额度受限或宕机时工作中断的痛点，通过统一代理层把多家模型接入到你已有的客户端里。

核心功能： - **多服务商聚合 + 自动故障转移**：配置多个模型后，当前服务商重试耗尽会自动切换到下一个模型，无需重启对话轮次。 - **多 Agent 统一模型目录**：同一套模型配置可同时驱动 Claude Code、Codex、Cline、Aider、VS Code Chat 等 11 种编码工具。 - **Token 用量优化**：通过 RTK 过滤命令输出、Headroom 压缩工具结果，并内置 5 项本地优化（配额探测、命令前缀识别、标题、建议、文件路径），号称最高降低 90% token 消耗。 - **多端接入**：支持终端、VS Code、JetBrains、Codex App、Discord、Telegram，以及浏览器内的原生 Codex 会话。 - **语音输入**：通过本地 Whisper 或 NVIDIA NIM 转写语音笔记，直接转为编码指令。

适用场景：适合预算敏感但想体验多种 AI 编程 Agent 的开发者、需要跨多个模型做对比测试的团队，以及希望在服务商宕机时保持编码不中断的重度用户。也适合喜欢在手机或 Discord/Telegram 上远程指挥 Agent 的人。

技术亮点：项目用 Python 3.14 + uv 构建，工具链选型激进（ty 做类型检查、ruff 格式化、loguru 日志、pytest 测试），说明作者追求现代化工程实践。架构上是一个中间代理层，把不同服务商的 API 差异抹平后暴露给各类客户端，同时保留流式响应、工具调用和原生 interleaved thinking。值得注意的是它强调"ToS-friendly"，会主动移除不再被服务商允许的集成，这在灰色地带项目中是相对克制的做法。

上手建议：最快路径是用 README 提供的一行安装脚本（macOS/Linux 用 curl，Windows 用 PowerShell），然后按文档选择一个服务商、连接你的客户端即可。想深入的话，建议先读

`scripts/` 下的安装脚本了解它如何注入配置，再看 providers 和 clients 的适配层代码。贡献方向上，新增服务商适配器或客户端集成是门槛较低、价值明确的切入点；由于采用 AGPL v3，二次分发需注意开源义务。

数据来源：github.com/trending

报告日期：2026-10-12

由 DeepSeek AI 提供智能分析 | 自动生成